

Mandelbrot Fractal Neural Synthesis: Zero-Storage Procedural Weight Derivation and Non-Linear Decision Boundaries

Volkan Dağlı^{1,*} • Dr. Zerrin Dağlı²

¹ITouch Bilişim Sistemleri (ITouch Systems), Turkey • itouch.com.tr • E-posta: vdagli@aof.anadolu.edu.tr (arXiv: itouch)

²Mersin Üniversitesi, Bilgisayar ve Öğretim Teknolojileri Eğitimi Bölümü, Mersin, Türkiye • ORCID: [0000-0001-9490-6465](https://orcid.org/0000-0001-9490-6465) • E-posta: 21010190002@mersin.edu.tr (arXiv: jesmaat)

*Sorumlu Yazar • Resmi Kod ve Deney Havuzu: github.com/pCwOrM/mandelbrot-fractal-neural-synthesis

Matris Standardı: 128 × 128 Piksel (15x Hızlı)	Ayrıştırma Modeli: 4-Quadrant Bölümleme	Hesaplama Motoru: Vectorized NumPy (Python 3.11)
Doğrulan Problem: AND, OR, NAND, NOR, XOR	Başarı Oranı: %100 Doğruluk	Kalıcı Bellek İzi: SADECE 24 BYTE (3 Sayı)
Açık Kaynak Kod & İnteraktif Laboratuvar: github.com/pCwOrM/mandelbrot-fractal-neural-synthesis		Kalıcı Tensör Matrisi: 0 BYTE (Sıfır Depolama)

ÖZET (ABSTRACT)

Modern derin öğrenme sistemleri, milyarlarca ve hatta trilyonlarca parametrenin yüksek boyutlu tensör matrislerinde bağımsız skaler değerler olarak saklanması ve geriye yayılım (backpropagation) ile güncellenmesi esasına dayanır. Bu mimari muazzam başarılar getirmekle birlikte; devasa bellek ayak izi, enerji tüketimi ve aşırı parametre fazlalığı (over-parametrization) gibi temel darboğazları barındırır. Bu çalışmada, yapay sinir ağlarında ağırlık ve sapma (bias) katsayılarının bağımsız sayılar olarak saklanması yerine; deterministik kaos ve fraktal morfolojinin en bilinen örneği olan **Mandelbrot kümesinin görsel işlenmesi** yoluyla dinamik olarak sentezlendiği alternatif bir parametrizasyon paradigması önerilmiş ve deneysel olarak doğrulanmıştır.

Sistemde, karmaşık düzlemdeki üç parametre $\theta = (c_x, c_y, \text{zoom})$ ile tanımlanan 128×128 piksellik bir pencere açılmakta; kaçış testi sonrasında kümenin ıraksamayan iç çekirdeğini temsil eden **"karanlık alan" (siyah pikseller)** oranı hesaplanmaktadır. Önerilen **4-Quadrant (Dört Çeyrek)** ayrıştırma metoduyla, tek bir fraktal görüntü karesi dört bağımsız parametreye (w_1, w_2, w_3, b) dönüştürülmüştür. Yapılan testlerde 128×128 çözünürlüğün, 256×256 ile %0.08 farkla aynı kararlılığı sağlarken **15 kat daha hızlı** (~16 ms) hesaplama yaptığı belirlenmiş; tüm temel mantık kapıları ve doğrusal olmayan **XOR problemi** %100 başarıyla çözülerek 2D non-linear karar yüzeyi inşa edilmiştir.

%100

Doğrusal Mantık Kapıları Başarısı (AND, OR, NAND, NOR)

%100

Doğrusal Olmayan (Non-Linear) XOR Çözüm Doğruluğu

1. Giriş ve Kavramsal Çerçeve (Introduction & Motivation)

1.1. Derin Öğrenmede Parametre Depolama Krizi

Modern yapay zeka ve Büyük Dil Modelleri (LLM'ler), eğitim sürecinde elde ettikleri bilgileri devasa tensör matrislerinde bağımsız kayan noktalı sayılar (FP32, FP16, INT8) olarak saklar. Güncel bir 70 milyar parametrelili model, yalnızca ağırlık tensörlerini GPU VRAM'inde tutabilmek için ~140 GB yüksek hızlı belleğe ihtiyaç duymaktadır. Bu durum bellek bant genişliği sınırına (memory wall), yüksek enerji tüketimine ve modellerin donanımsal taşınabilirliğinde ciddi engellere yol açmaktadır.

1.2. Fraktal Morfoloji ve Zihinsel İlham

Doğadaki birçok karmaşık yapı (akciğer alveolleri, beyindeki dendritik dallanmalar, sahil şeritleri, kan damarı şebekeleri), trilyonlarca bağımsız koordinat noktasıyla kodlanmaz. İnsan DNA'sı yaklaşık 750 megabaytlık bir bilgi kapasitesine sahipken, insan beyinde 86 milyar nöron ve yaklaşık 100 trilyon sinaps bulunur. Buradaki matematiksel gerçek açıktır: *Gelişimsel biyoloji, tüm bağlantıları tek tek saklamak yerine, basit ve özyinelemeli (recursive) büyüme kurallarını icra eder.*

Mandelbrot kümesi, matematiğin en saf ve kompakt özyinelemeli sistemidir. Tek satırlık bir kuadratik fonksiyon ($z \leftarrow z^2 + c$), sonsuz çeşitlilikte, kendine benzer (self-similar) ve ölçekten bağımsız mikro-yapılar üretir. Bu projenin temel araştırma sorusu şudur:

Temel Araştırma Hipotezi

"Bir yapay sinir ağının ihtiyaç duyduğu ağırlık ve eşik matrisleri, bağımsız değişkenler olarak saklanmak yerine; deterministik kaotik bir fraktal uzaydaki koordinat ve zoom pencerelerinin görsel işlenmesi yoluyla dinamik olarak üretilebilir mi?"

1.3. Literatürdeki Yeri ve Benzer Yaklaşımlar

- HyperNEAT & CPPN (Compositional Pattern Producing Networks):** Kenneth Stanley ve ekibinin öncülük ettiği HyperNEAT yaklaşımında, ağ ağırlıkları uzamsal koordinatları (x_1, y_1, x_2, y_2) girdi alan bir fonksiyondan türetilir. Ancak CPPN'de bu fonksiyon yine yapay bir sinir ağıdır. Bizim çalışmamızda ise parametre üretici doğrudan Mandelbrot'un analitik dinamik sistemidir.
- FractalNet:** Derin konvolüsyonel ağlarda katman bağlantılarını fraktal bir hiyerarşiyle bağlar. Ancak FractalNet'te ağırlıkların kendisi klasik tensörlerdir. Bizim çalışmamız mimariyi değil, ağırlıkların kendisini fraktal morfolojiden okur.

2. Matematiksel Modelleme ve Metodoloji (Methodology)

2.1. Mandelbrot Dinamik Sistemi

Karmaşık düzlemdeki her bir $c = c_x + i c_y \in \mathbb{C}$ noktası için kuadratik iterasyon tanımlanır:

$$z_0 = 0, \quad z_{n+1} = z_n^2 + c$$

Eğer bir c noktası için $|z_n| > 2.0$ eşiği aşılsa, dizinin sonsuza ıraksayacağı analitik olarak ispatlanmıştır. Kaçış yarıçapını aşmayan noktalar kümenin içindedir:

$$\mathcal{M} = \{ c \in \mathbb{C} : \limsup_{n \rightarrow \infty} |z_n| \leq 2.0 \}$$

2.2. Sayısal Örnekleme ve Karanlık Alan (Black Ratio) Entegrasyonu

Mandelbrot kümesinin alanı analitik bir formülle hesaplanamaz. Bu nedenle belirli bir merkez (c_x, c_y) ve $s = 1 / \text{zoom}$ genişliğindeki pencere $N \times N$ boyutunda piksellere bölünerek sayısal Monte Carlo entegrasyonu uygulanır:

$$R_{\text{black}} = \frac{1}{N^2} \sum_{j=0}^{N-1} \sum_{k=0}^{N-1} \mathbb{I}(\left| z_{M_{\text{max}}}(C_{j,k}) \right| \leq 2.0), \quad R_{\text{black}} \in [0.0, 1.0]$$

2.3. 4-Quadrant (Dört Çeyrek) Parametre Ayrıştırma Mekanizması

Her ağırlık için ayrı bir pencere aramak hesaplama yükünü katlayacağından, tek bir 128×128 fraktal pencere 4 eşit kadrana (64×64) bölünerek nöronun tüm katsayıları eşzamanlı çıkarılmıştır:

$$w_1 = (R_{Q_1} - 0.5) \times 6.0, \quad w_2 = (R_{Q_2} - 0.5) \times 6.0, \quad w_3 = (R_{Q_3} - 0.5) \times 6.0, \quad b = (R_{Q_4} - 0.5) \times 6.0$$



Bu formülasyon sayesinde türetilen katsayılar yapay nöron aktivasyonuna en uygun aralık olan **[-3.0, +3.0]** bandına haritalanmaktadır.

3. Deneysel Kurulum ve Doğrulama Protokolü (Experimental Results)

3.1. Deney 1: Çözünürlük Duyarlılığı ve Kararlılık Analizi

Piksel sayma yönteminde çözünürlüğün ($N \times N$) kararlılık ve işlem süresi üzerindeki etkisi 4 farklı bölgede kıyaslanmıştır:

Bölge ve Parametreler	32 × 32	64 × 64	128 × 128 (Standart)	256 × 256	128 vs 256 Sapma
Ana Kardioid Gövdesi (1.0x)	%36.72 (4.3 ms)	%37.55 (5.2 ms)	%38.11 (14.9 ms)	%38.44 (187.2 ms)	%0.33
Seahorse Valley (Sınır) (500x)	%20.02 (3.1 ms)	%20.31 (9.8 ms)	%20.68 (19.6 ms)	%20.60 (234.9 ms)	%0.08
Mini-Mandelbrot Uydusu (25x)	%8.20 (2.1 ms)	%8.50 (6.2 ms)	%8.53 (15.6 ms)	%8.62 (86.9 ms)	%0.09
Elephant Valley (50x)	%71.19 (2.5 ms)	%70.78 (4.8 ms)	%70.39 (17.3 ms)	%70.30 (311.7 ms)	%0.09




Şekil 1: Çözünürlüğe bağlı karanlık alan oranı kararlılığı (%) ve hesaplama süreleri (ms). 128×128 çözünürlük 256'ya göre 15 kat hızlıdır.

Deneysel Çıkarım: 128×128 "Sweet Spot" Noktası

32×32 ve 64×64 çözünürlüklerde sınır fraktallarında pikselleşme gürültüsü nedeniyle ~%1-2 sapma gözlemlenirken; 128×128 çözünürlük 256×256 ile %0.08 farkla aynı sonucu vermiş ve sadece 15 ms'de hesaplanarak optimum standart olarak tescillenmiştir.


3.2. Deney 2: Zoom Katsayısı ve Kaotik Salınım Dinamikleri

Seahorse Valley sınırında zoom seviyesi 1.0x ile 50,000x arasında logaritmik taranmıştır. Fraktalın kendi kendine benzer mikro kopyalarına girip çıktıkça siyah alan oranı tekdüze artıp azalmamış, deterministik kaotik tepeler ve vadiler oluşturmuştur:



Şekil 2: Seahorse Valley sınırında logaritmik zoom artışına bağlı siyah alan oranı, kaçış süresi ve türetilen bias katsayısı.


Mandelbrot Fraktal Pencereleeri ve Nöron Tepkileri



Şekil 3: Ana Gövde, Seahorse Valley ve Dış Kaçış bölgelerinden alınan pencereler ve siyah alan maskeleri.

3.3. Deney 3: 4-Quadrant Çoklu Ağırlık Ayırıştırması

128×128 boyutundaki tek bir pencere yatay ve dikey eksenlerde ikiye bölünerek 4 eşit çeyrek elde edilmiş ve nöronun w_1 , w_2 , w_3 ve bias katsayıları eşzamanlı türetilmiştir:




Şekil 4: 128×128 Mandelbrot penceresinin 4 kadrana bölünerek nöron parametrelerine dönüştürülmesi.

3.4. Deney 4: Temel Mantıksal Kapıların %100 Optimizasyonu (AND, OR, NAND, NOR)

Her kapı için evrimsel tepe tırmanma (random-walk search) algoritması çalıştırılmış ve tüm kapılar **%100 doğrulukla** çözülmüştür:

Mantık Kapısı	Merkez Koordinat (c_x, c_y)	Zoom	Türetilen w_1	Türetilen w_2	Türetilen Bias (b)	Başarı Oranı
OR Kapısı	(-0.055780, 0.806329)	110.1×	+3.000	+2.432	-0.117	%100 DOĞRU ✓
AND Kapısı	(-0.144732, 0.758854)	4.5×	+0.785	+1.359	-1.777	%100 DOĞRU ✓
NAND Kapısı	(-0.740191, 0.174654)	3417.7×	-1.370	-1.169	+2.074	%100 DOĞRU ✓
NOR Kapısı	(-0.523561, 0.525212)	1123.5×	-1.469	-2.518	+0.151	%100 DOĞRU ✓



Şekil 5: Temel mantık kapılarını %100 doğrulukla çözen 128×128 Mandelbrot pencereleri.

3.5. Deney 5: Doğrusal Olmayan (Non-Linear) XOR Probleminin %100 Çözümü


1969 yılında Marvin Minsky ve Seymour Papert tarafından ispatlandığı üzere, tek bir yapay nöron (algılayıcı) XOR problemini çözemez; çünkü XOR uzayında (0,1) ve (1,0) noktaları tek bir düz çizgiyle (hiperdüzlemle) (0,0) ve (1,1) noktalarından ayıramaz.

Bu engeli aşmak için iki adet bağımsız 128×128 Mandelbrot penceresi ile beslenen **2 katmanlı bir fraktal sinir ağı** inşa edilmiştir:

$$\begin{aligned} h_1 &= \sigma(w_{11} x_1 + w_{12} x_2 + b_1) \quad \text{[Nöron 1: 128x128 OR Ajanı]} \\ h_2 &= \sigma(w_{21} x_1 + w_{22} x_2 + b_2) \quad \text{[Nöron 2: 128x128 NAND Ajanı]} \\ \hat{y} &= \sigma(v_1 h_1 + v_2 h_2 + b_3) \quad \text{[Çıkış Katmanı: Karar Birleştirici]} \end{aligned}$$

Girdi (x_1, x_2)	Hedef y	h_1 (OR)	h_2 (NAND)	Çıktı $\sigma(z)$	Tahmin	Doğrulama
(0, 0)	0	0.471	0.889	0.302	0	BAŞARILI ✓
(0, 1)	1	0.911	0.716	0.681	1	BAŞARILI ✓
(1, 0)	1	0.947	0.670	0.669	1	BAŞARILI ✓
(1, 1)	0	0.995	0.388	0.332	0	BAŞARILI ✓

Fraktal Ağırlıklarla %100 Çözülen 2-Katmanlı XOR Derin Sinir Ağı



Şekil 6: Sol ve Orta: Nöron 1 (OR) ve Nöron 2 (NAND) 128×128 pencereleri. Sağ: Fraktal ağı oluşturduğu doğrusal olmayan (non-linear) 2D XOR karar yüzeyi.

4. Handikaplar, Riskler ve Teorik Kısıtlar (Challenges & Limitations)

Bu yöntemin teorik sınırlarını ve pratik engellerini dürüstçe ortaya koymak akademik tarafsızlığın gereğidir:

1. Türevlenemezlik (Non-Differentiability) ve Geriye Yayılım Engeli

Mandelbrot kaçış testi kesikli (discrete) bir adımdır. Bir noktanın 79. iterasyonda kaçması ile 80. iterasyonda kaçması arasında analitik bir türev yoktur ($\partial R / \partial c_x$ tanımsızdır). Bu durum, derin öğrenmenin ana motoru olan **Geriye Yayılım (Backpropagation)** ve Gradyan İnişini (SGD, Adam) imkansız kılar. Model ancak Genetik Algoritmalar gibi türevsiz arama yöntemleriyle eğitilebilir.

2. Hesaplama Karmaşıklığı ve Gecikme (Latency)

Geleneksel bir GPU'da ağırlık matrisi bellekten $O(1)$ maliyetle tek saat çevriminde okunurken; bir Mandelbrot penceresi üretmek $O(N^2 \times M_{iter})$ işlem gerektirir. 128×128 boyutunda bir pencere tek bir nöronda ~15 ms sürerken, bir LLM'deki trilyonlarca parametre için bu işlemi dijital CPU/GPU'da çalıştırmak pratik değildir.

3. Kaotik Hassasiyet ve Sayısal Kararsızlık (Butterfly Effect)

Fraktal sınırlarda Lyapunov üssü pozitif olduğundan, koordinatta 10^{-7} mertebesinde bir değişim siyah alan oranını tamamen tersine çevirebilir. Bu durum parametre arama uzayını son derece engebeli ve yerel minimumlarla dolu hale getirir.

4. Doygunluk ve Temsil Kapasitesi Sınırı

Derin zoom seviyelerinde pencere tamamen siyah (%100) ya da tamamen kaçış (%0) bölgesine denk gelebilir. Bu bölgelerde ağırlık doyuma ulaşır (saturation) ve bilgi akışı kesilir.

5. Nasıl Geliştirilebilir? İleri Araştırma Rotaları (Future Enhancements)

5.1. Sürekli ve Diferansiyellenebilir Fraktal Metrikleri

- Mesafe Tahmin Yöntemi (DEM - Distance Estimation Method):** Piksellerin Mandelbrot sınırına olan mesafesini hesaplayan analitik potansiyel fonksiyonu kullanılarak sürekli ve yumuşak geçişli bir ağırlık alanı elde edilebilir.
- Soft-Escape Aktivasyonu:** İkili (0/1) kesme fonksiyonu yerine sıcaklık parametrelili sigmoid kullanılarak PyTorch Autograd ile kısmi gradyan akışı simüle edilebilir.

5.2. Dinamik Girdi Yönlendirmesi (Input-Conditioned Steering)

Girdi vektörü (x_1, x_2) , fraktal pencerenin merkez koordinatını dinamik olarak kaydırabilir:

$$c_x(x) = c_0 + \alpha x_1, \quad c_y(x) = c_0 + \beta x_2$$

Bu sayede nöron, her girdiye göre fraktalda farklı bir noktaya bakarak "Girdiye Göre Kendi Kendini Modüle Eden Ağırlıklar" (Dynamic Hypernetworks) üretebilir.

5.3. Fraktal Boyut ve Bilgi Entropisi

Yalnızca piksel saymak yerine, penceredeki fraktal sınırın *Kutu-Sayma Boyutu (Box-Counting Dimension)* veya kaçış süresi varyansı ek bir tensör parametresi olarak modele entegre edilebilir.

6. Uygulama Alanları: Nerede ve Nasıl Kullanılabilir? (Applications)

1. Ekstrem Model Sıkıştırma (Procedural Weights)

Yüzlerce gigabaytlık model ağırlıkları yerine; tüm katmanların küçük bir fraktal tohum koordinat defteri (c_x, c_y, zoom) olarak saklanması.

2. Kriptografik ve Güvenli Yapay Zeka

Ağırlıklar model dosyasında açık bulunmaz; yalnızca gizli koordinat anahtarına sahip kullanıcı tarafından çalışma anında fraktaldan açılır (Reverse-engineering koruması).

3. Fotonik ve Optik Nöral İşlemciler

Işık dalgalarının optik kırınımıyla analog fraktal girişim haritaları oluşturulabilir; piksel sayımı fotodedektörle tek bir nanosaniyede sıfır gecikmeyle okunabilir.

4. Kuantum Kaos Hesaplama

Kuantum durumlarının süperpozisyon ve dalga çökme olasılıkları fraktal dinamiklerle doğrudan örtüştürülebilir.

7. Sonuç ve Genel Değerlendirme (Conclusion)

Bu araştırma; deterministik kaos ve fraktal geometrinin yapay sinir ağları için işlevsel, zengin ve çok boyutlu bir parametrisasyon motoru olarak kullanılabileceğini kavramsal ve deneysel düzeyde kanıtlamıştır.

Klasik dijital GPU mimarilerinde piksel sayma maliyeti doğrudan bellek okumanın yerini alamasa da; önerilen **128×128 4-Quadrant ayrıştırma mimarisi** temel doğrusal kapılarda ve doğrusal olmayan XOR probleminde **%100 doğrulukla** çalışarak fraktal yapay zeka alanında sağlam bir Proof-of-Concept inşa etmiştir. Bu paradigma; geleceğin optik işlemcileri, kuantum algoritmaları ve prosedürel ağırlık sıkıştırma mimarileri için ezber bozan yeni bir teorik zemin sunmaktadır.

8. Ek: Doğrulama Kaynak Kodu (Reproducible Python Code)

```
import numpy as np

def compute_mandelbrot_patch_128(cx, cy, zoom, res=128, max_iter=70):
    scale = 1.0 / zoom
    x = np.linspace(cx - scale, cx + scale, res)
    y = np.linspace(cy - scale, cy + scale, res)
    C = x[np.newaxis, :] + 1j * y[:, np.newaxis]
    Z = np.zeros_like(C)
    escape_iters = np.full(C.shape, max_iter, dtype=int)
    mask = np.ones(C.shape, dtype=bool)

    for i in range(max_iter):
        Z[mask] = Z[mask]**2 + C[mask]
        escaped = np.abs(Z) > 2.0
        escape_iters[escaped & mask] = i
        mask = mask & (~escaped)

    # 4-Quadrant Ağırlık Ayrıştırması (w1, w2, w3, bias)
    mid = res // 2
    quads = [escape_iters[:mid, :mid], escape_iters[:mid, mid:],
             escape_iters[mid:, :mid], escape_iters[mid:, mid:]]
    weights = [((np.sum(q == max_iter) / q.size) - 0.5) * 6.0 for q in quads]
    return weights[0], weights[1], weights[3] # w1, w2, bias
```